

Resumen de todas las arquitecturas

Resumen de todas las arquitecturas entrenadas para la predicción latido a latido de dRR, con la selección final y el resultado en test.

Selección final: tcn_lite_ft_int8 - una TCN causal (24 filtros, dilataciones 1/2/4/7, campo receptivo de 29 latidos) sobre los últimos 30 intervalos RR más 9 características diseñadas, que predice una corrección sobre un pronóstico RLS AR(8) adaptativo. 8 048 MACs por latido y 8.4 KB de pesos int8. No pierde frente a ningún otro candidato en el lazo cerrado int8 en validación y cumplió todas las reglas sobre los sujetos de test reservados.

Objetivo y restricciones

- Predecir $dRR[n+1] = RR[n+1] - RR[n]$ latido a latido a partir de los últimos 30 intervalos RR, para rellenar latidos perdidos en tiempo real en un marcapasos (notebooks/correlation_study_v3.ipynb).
- Primer hardware: STM32H750 (Cortex-M7); el implante será menos potente. Presupuesto estricto: como máximo 10k MACs por latido (preferible 3k), pesos int8 de como máximo 32 KB, RMSE int8 a menos del 2% del float, solo operaciones nativas del MCU (Conv1D, SeparableConv1D, Dense, BatchNorm, ReLU, Add, relleno causal, GRU), campo receptivo de como máximo 30.
- Datos: series RR en data/series/*.txt, divididas por sujeto: 142 sujetos de entrenamiento, 16 de validación y 10 de test (data/subjects_*.json, estratificados por intervalo de edad). La selección se hizo solo en validación; el conjunto de test se abrió una única vez, para la evaluación final.
- Regla de selección (decisiones del usuario): dentro del presupuesto, primero la precisión, decidida por el lazo CERRADO del modelo int8 con pruebas de Wilcoxon pareadas por sujeto (agrupando las tasas de eliminación o por tasa con Bonferroni, nunca significativamente peor en ninguna tasa); los empates reales los gana el modelo más pequeño. Además se comprueba en cada modelo la fidelidad de la RSA (ningún pico respiratorio inventado ni desplazado).

Arquitecturas comparadas (mejor variante de cada familia)

familia	mejor variante	MACs/latido	tamaño int8	val lazo abierto	val cerrado 10%	val cerrado 80%	test serie completa 80%	documento
tcn_lite	tcn_lite_ft	8048	8.4 KB	32.62	25.87	41.66	43.74	08_tcn_lite.pdf
micro_tcn	micro_tcn	2080	2.4 KB	32.93	26.32	41.86	43.84	07_micro_tcn.pdf
gru	gru	1696	1.8 KB	33.90	28.04	45.07	43.84	06_gru.pdf
mlp	mlp	1136	1.2 KB	34.60	27.07	42.25	44.30	04_mlp.pdf
gbdt	gbdt	3000 comparaciones	238 KB (30 500 nodos)	34.19	25.53	43.16	45.85	05_gbdt.pdf
linear	linear	9	10 parám.	40.46	30.34	43.36	45.67	03_linear.pdf
TCN_MHA (heredado)	tcn_mha_current	2 040 576	75.5 KB	33.72	26.07	43.88	50.11	09_tcn_mha.pdf
referencia	rls_ar	152 FLOPs	-	37.14	28.88	53.73	49.15	02_baselines.pdf

RMSE en ms. **val lazo abierto**: predicción a un paso sobre la historia verdadera, 16 sujetos de validación. **10-80%**: lazo cerrado (uso en el marcapasos) en validación: se elimina al azar esa proporción de latidos desde el latido 0, cada uno se rellena con el modelo y se realimenta; RMSE sobre los latidos rellenados por el modelo, primeros 5000 latidos por sujeto, media de las semillas de esa ronda (3 semillas desde la ronda 2). Se usa int8 donde existe. **RSA inventada**: proporción de pares sujeto-ejecución cuya serie rellenada gana un pico de RSA que la original no tiene. **test serie completa 80%**: diagnóstico sobre los 10 sujetos de test (serie completa, semilla 7, carpeta results/test/); no se usó para ninguna selección.

Test final (conjunto de test reservado, ejecutado una vez, 10 sujetos, 942 526 ventanas)

modelo	lazo abierto	cerrado 10%	cerrado 30%	cerrado 50%	cerrado 80%
tcn_lite_ft_int8 (desplegado)	28.59	28.25	30.20	33.07	41.55
tcn_lite_ft (float)	28.44	28.04	29.96	32.92	41.54
TCN_MHA (heredado)	29.11	28.58	30.63	33.90	42.53
rls_ar	31.15	29.94	32.54	36.09	54.36
persistence	36.80	33.77	36.74	39.37	46.72

- `tcn_lite_ft_int8` es mejor que `rls_ar` en 10/10 sujetos de test en lazo abierto (-8.2%) y en el lazo cerrado agrupado; con el 80% eliminado es 9 ms (23.6%) mejor. La ganancia al 10% ya no es significativa en test.
- En los sujetos de test no inventa ni desplaza ningún pico de RSA en ninguna tasa de eliminación; con el 80% eliminado amortigua la potencia de la RSA, lo que un análisis de viabilidad mostró que es un límite de información (la fase de la RSA no se puede recuperar con el 20% de los latidos), no un defecto del modelo.
- El TCN_MHA heredado es peor en 10/10 sujetos en lazo abierto, inventa picos de RSA y no puede ejecutarse en el MCU.

Correlación entre la serie original y la rellenada (sujetos de validación y test, todos los modelos)

modelo	corr RR validación	corr RR test	corr dRR validación	corr dRR test	RMSE rellenados, validación (ms)	RMSE rellenados, test (ms)
<code>micro_tcn_dad</code>	0.9386	0.9423	0.281	0.272	49.10	42.95
<code>tcn_lite_dad</code>	0.9383	0.9425	0.282	0.278	49.26	42.91
<code>tcn_lite_ft</code>	0.9356	0.9395	0.272	0.266	50.15	43.62
<code>micro_tcn</code>	0.9354	0.9396	0.274	0.264	50.28	43.84
<code>tcn_lite_ft_int8</code>	0.9354	0.9393	0.269	0.263	50.18	43.74
<code>tcn_lite</code>	0.9352	0.9394	0.270	0.264	50.27	43.73
<code>gru</code>	0.9352	0.9397	0.266	0.263	50.24	43.84
<code>tcn_lite_rsa_ws</code>	0.9350	0.9385	0.270	0.260	50.40	43.97
<code>mlp</code>	0.9348	0.9390	0.265	0.263	50.63	44.30
<code>micro_tcn_rsa_ws</code>	0.9348	0.9384	0.272	0.257	50.67	44.44
<code>mlp_nobp</code>	0.9331	0.9379	0.264	0.259	51.60	45.00
<code>linear</code>	0.9328	0.9359	0.253	0.241	51.24	45.67
<code>micro_tcn_rsa</code>	0.9326	0.9373	0.263	0.260	51.87	45.37
<code>gbdt_all</code>	0.9321	0.9365	0.257	0.250	51.62	45.51
<code>gbdt</code>	0.9312	0.9359	0.248	0.244	51.99	45.85
<code>tcn_lite_rsa</code>	0.9311	0.9337	0.261	0.246	51.87	45.97
<code>micro_tcn_f8</code>	0.9299	0.9356	0.257	0.252	52.33	46.18
<code>ema_mean</code>	0.9289	0.9328	0.243	0.228	52.67	46.78
<code>persistence</code>	0.9221	0.9260	0.216	0.213	56.05	48.55
<code>rls_ar</code>	0.9186	0.9276	0.202	0.219	56.34	49.15
<code>mlp_rsa</code>	0.9159	0.9172	0.230	0.208	58.59	54.24
<code>tcn_mha_current</code>	0.9158	0.9218	0.189	0.179	57.45	50.11

Calculado sobre los 16 sujetos de validación y los 10 de test (carpetas `results/validation/` y `results/test/`), sobre la serie COMPLETA, tras eliminar el 80% de los latidos (semilla 7, desde el latido 0) y rellenarlos en lazo cerrado con el modelo (relleno Burg-AR en los primeros 30 latidos): **corr RR** = `np.corrcoef(original_serie, modified_serie)[0, 1]`; **corr dRR** = la misma función sobre los cambios latido a latido, `np.corrcoef(np.diff(original), np.diff(filled))[0, 1]`, que aísla la dinámica a corto plazo. Media sobre sujetos; valores por sujeto en `<carpeta>/crosscorr.csv`. **RMSE rellenados**: RMSE sobre los latidos rellenados por el modelo en esas mismas ejecuciones. Diagnóstico: la selección usó el protocolo de la ronda 4, no estas ejecuciones.

- Nivel RR: todos los modelos mantienen una correlación alta con la original (validación 0.916-0.939, test 0.917-0.942): dominan los cambios lentos de frecuencia cardiaca y el 20% de latidos conservados los ancla. El modelo desplegado `tcn_lite_ft_int8`: validación 0.9354 (puesto 5 de 22), test 0.9393 (puesto 7); `rls_ar` 0.9186 / 0.9276; `TCN_MHA` 0.9158 / 0.9218 (validación / test).
- El nivel dRR (dinámica latido a latido) separa más a los modelos: `tcn_lite_ft_int8` 0.269 / 0.263, `rls_ar` 0.202 / 0.219, `TCN_MHA` 0.189 / 0.179 (validación / test); el más bajo: `tcn_mha_current` en validación, `tcn_mha_current` en test. Valores en torno a 0.2-0.3 son esperables con el 80% eliminado: 4 de cada 5 cambios latido a latido son del propio modelo.
- Mayor correlación RR: `micro_tcn_dad` en validación, `tcn_lite_dad` en test. Estas ejecuciones sobre la serie completa son diagnósticos; la selección se hizo con el protocolo de validación de la ronda 4 y no cambia.

Documentos de esta carpeta

archivo	contenido
00_overview.pdf	este resumen
01_feature_engineering.pdf	el motor de características en streaming, preprocesado, objetivos, protocolos de lazo cerrado e int8
02_baselines.pdf	persistencia, media EMA, RLS AR(8) adaptativo
03_linear.pdf	regresión ridge sobre dRR retardados (AR global)
04_mlp.pdf	MLP sobre características diseñadas: mlp, mlp_nobp, mlp_rsa
05_gbdtdt.pdf	árboles potenciados por gradiente: gbdtdt, gbdtdt_all (referencia de precisión y de importancia de características)
06_gru.pdf	GRU sobre la secuencia RR + características
07_micro_tcn.pdf	TCN causal separable, 16 filtros, y sus variantes
08_tcn_lite.pdf	TCN causal completa, 24 filtros, y sus variantes, incluida la seleccionada tcn_lite_ft
09_tcn_mha.pdf	la TCN heredada con atención multicabeza (modelo de producción actual)

Abreviaturas y siglas usadas en este documento

término	significado
AR	autorregresivo: un valor predicho como suma ponderada de valores pasados; AR(p) usa p valores pasados
ar	nombre de conjunto de características: entradas autorregresivas (rr_dev y los 8 dRR más recientes) del modelo lineal
Burg-AR	modelo AR cuyos coeficientes se ajustaron con el método de Burg (usado en los primeros 30 latidos)
Conv1D	capa de convolución unidimensional
Cortex-M7	Arm Cortex-M7, el núcleo de procesador del microcontrolador STM32H750
_dad	sufijo de nombre de ejecución: ajuste fino con datos DAD (rellenados en lazo cerrado)
dRR	cambio latido a latido del intervalo RR: $dRR[n+1] = RR[n+1] - RR[n]$ (ms); la magnitud que se predice
EMA	media móvil exponencial
ema_mean	referencia que predice el siguiente RR como media móvil exponencial de la ventana
_f8	sufijo de nombre de ejecución: 8 filtros de convolución en lugar de 16
FLOPs	operaciones de coma flotante (coste aritmético)
_ft	sufijo de nombre de ejecución: ajuste fino (entrenamiento continuado desde los pesos del modelo padre)
gbdt	árboles de decisión potenciados por gradiente (nombre de ejecución)
GRU	unidad recurrente con compuertas (celda de red neuronal recurrente)
gru	unidad recurrente con compuertas (nombre de ejecución)
HRV	variabilidad de la frecuencia cardiaca
int8	entero de 8 bits: pesos y activaciones cuantizados a enteros de 8 bits, como se ejecuta en el microcontrolador; _int8 = la versión int8 de una ejecución
KB	kilobyte (1024 bytes)
MAC	operación de multiplicación-acumulación (una multiplicación más una suma): la unidad de coste de cómputo en el microcontrolador; MACs/latido = cuántas necesita el modelo por latido
MACs	operaciones de multiplicación-acumulación (ver MAC)
MCU	microcontrolador
MHA	atención multicabeza (capa de tipo transformer, no soportada por la cadena de herramientas del MCU)
MLP	perceptrón multicapa (red neuronal totalmente conectada)
mlp	perceptrón multicapa (nombre de ejecución)
ms	milisegundos
nobp	parte del nombre de ejecución: sin pasa banda (se quitan las características bp y bp_prev del pasa banda RSA fijo)
np.corrcoef	función de NumPy para el coeficiente de correlación de Pearson
np.diff	función de NumPy de diferencias sucesivas
ReLU	unidad lineal rectificada, $\max(0, x)$ (función de activación)
RLS	mínimos cuadrados recursivos: filtro adaptativo que actualiza sus coeficientes en cada latido
rls_ar	referencia: pronóstico AR(8) adaptativo por paciente mediante RLS
RMSE	raíz del error cuadrático medio (ms): la medida principal de precisión, menor es mejor
RR	intervalo RR: tiempo entre dos latidos consecutivos (ondas R del ECG), en ms
RSA	arritmia sinusal respiratoria: la oscilación de la frecuencia cardiaca provocada por la respiración
_rsa	sufijo de nombre de ejecución: usa las características del seguidor de RSA
SeparableConv1D	convolución 1-D separable en profundidad: una convolución por canal seguida de una puntual (mucho más barata que Conv1D)
STM32H750	microcontrolador de 32 bits de STMicroelectronics (Arm Cortex-M7, 128 KB de flash, 1 MB de RAM)
TCN	red convolucional temporal (convoluciones 1-D causales y dilatadas)
tcn	red convolucional temporal (parte del nombre de ejecución)
val	validación: los 16 sujetos de validación, usados para seleccionar el modelo
_ws	sufijo de nombre de ejecución: arranque en caliente (inicializado con los pesos del padre, entradas nuevas a cero)