

Árboles potenciados por gradiente

HistGradientBoosting sobre las características tabulares: referencia de precisión y de importancia de características.

Los árboles potenciados por gradiente son una referencia tabular fuerte, pero demasiado grandes para el microcontrolador (unos 8 bytes por nodo).

Arquitectura

- HistGradientBoostingRegressor de scikit-learn: error cuadrático, tasa de aprendizaje 0.05, hasta 500 árboles de profundidad 6 (31 hojas), mínimo 100 muestras por hoja, L2 1.0, parada temprana sobre el conjunto de validación.
- 500 árboles, 30 500 nodos: unos 238 KB a 8 B por nodo, muy por encima del presupuesto de 32 KB, y unas 3000 comparaciones por predicción.
- Residual sobre el pronóstico RLS, como los modelos neuronales.

Entradas e ingeniería de características (gbdt)

- **Entrada tabular:** las características diseñadas del latido más reciente (ver 01_feature_engineering.pdf), normalizadas z por característica con estadísticas de entrenamiento.
- **Objetivo:** $dRR[n+1] = RR[n+1] - RR[n]$. Los modelos residuales predicen la corrección normalizada z sobre el pronóstico RLS ($dRR - rls_pred$); la salida se desnormaliza y se suma de nuevo a rls_pred .

Características tabulares (19):

característica	definición
rr_dev	RR más reciente menos la media de la ventana
rr_mean	RR medio de la ventana de 30 latidos
drr_lag0..7	drr_lag0..7: los 8 dRR más recientes (lag0 = el más nuevo)
rmssd	raíz cuadrada media de las 29 diferencias sucesivas
rs	rango reescalado: (máx - mín de la suma acumulada de RR - media) / desviación estándar
ccm	medida de correlación compleja: área de los triángulos de Poincaré / (pi SD1 SD2 (W-3)), recortada a [0, 1]
guzik	asimetría de Guzik: suma de dRR positivos / suma de dRR
rls_pred	pronóstico RLS AR(8) del siguiente dRR (ms), recortado a +-300
rls_err	última innovación del RLS: dRR verdadero menos el pronóstico anterior (ms)
bp	salida del pasa banda RSA: biquad RBJ sobre el RR crudo, centro 0.30 ciclos/latido, Q 1
bp_prev	salida anterior del pasa banda (junto con bp da la fase)
run_len	longitud con signo de la racha actual de dRR del mismo signo (+ = desaceleración)

Variantes entrenadas

ejecución	cambio respecto al padre	conjunto de características (n)	parám.	MACs/latido	entrenamiento	épocas
gbdt	19 características tabulares	tab (19)	-	-	desde cero, lr 0.001	-
gbdt_all	todas las características del motor (29 entonces)	29 características (29)	-	-	desde cero, lr 0.001	-

Resultados

modelo	val lazo abierto	modelo en lazo cerrado	10%	30%	50%	80%	RSA inventada al 80%	test serie completa 80%	fuentes val
gbdt	34.19	float	25.53	29.94	33.71	43.16	-	45.85	ronda 1
gbdt_all	-	float	-	-	-	-	-	45.51	-

RMSE en ms. **val lazo abierto:** predicción a un paso sobre la historia verdadera, 16 sujetos de validación. **10-80%:** lazo cerrado (uso en el marcapasos) en validación: se elimina al azar esa proporción de latidos desde el latido 0, cada uno se rellena con el modelo y se realimenta; RMSE sobre los latidos rellenados por el modelo, primeros 5000 latidos por sujeto, media de las semillas de esa ronda (3 semillas desde la ronda 2). Se usa int8 donde existe. **RSA inventada:** proporción de pares sujeto-ejecución cuya serie rellena gana un pico de RSA que la original no tiene. **test serie completa 80%:** diagnóstico sobre los 10 sujetos de test (serie completa, semilla 7, carpeta results/test/); no se usó para ninguna selección.

Correlación entre la serie original y la rellenada (sujetos de validación y test)

modelo	corr RR validación	corr RR test	corr dRR validación	corr dRR test	RMSE rellenados, validación (ms)	RMSE rellenados, test (ms)
gbdt	0.9312	0.9359	0.248	0.244	51.99	45.85
gbdt_all	0.9321	0.9365	0.257	0.250	51.62	45.51

Calculado sobre los 16 sujetos de validación y los 10 de test (carpetas results/validation/ y results/test/), sobre la serie COMPLETA, tras eliminar el 80% de los latidos (semilla 7, desde el latido 0) y rellenarlos en lazo cerrado con el modelo (relleno Burg-AR en los primeros 30 latidos): **corr RR** = `np.corrcoef(original_serie, modified_serie)[0, 1]`; **corr dRR** = la misma función sobre los cambios latido a latido, `np.corrcoef(np.diff(original), np.diff(filled))[0, 1]`, que aísla la dinámica a corto plazo. Media sobre sujetos; valores por sujeto en <carpeta>/crosscorr.csv. **RMSE rellenados**: RMSE sobre los latidos rellenados por el modelo en esas mismas ejecuciones. Diagnóstico: la selección usó el protocolo de la ronda 4, no estas ejecuciones.

Veredicto

- No desplegable (tamaño). Solo referencia de precisión: 34.2 ms en validación, entre el MLP y las TCNs.
- gbd_t_all (34.15 ms) muestra que las características extra no aportan nada; su importancia por permutación sitúa rls_pred primera con mucha diferencia, después rr_dev, drr_lag0, guzik y bp; los 8 pesos del RLS no aportan nada.

Abreviaturas y siglas usadas en este documento

término	significado
AR	autorregresivo: un valor predicho como suma ponderada de valores pasados; AR(p) usa p valores pasados
B	dimensión de lote (número de ventanas procesadas a la vez) en las formas de salida de las capas
bp	característica: salida del pasa banda RSA: biquad RBJ sobre el RR crudo, centro 0.30 ciclos/latido, Q 1
bp_prev	característica: salida anterior del pasa banda (junto con bp da la fase)
Burg-AR	modelo AR cuyos coeficientes se ajustaron con el método de Burg (usado en los primeros 30 latidos)
ccm	medida de correlación compleja: índice de no linealidad del diagrama de Poincaré de intervalos RR consecutivos
dRR	cambio latido a latido del intervalo RR: $dRR[n+1] = RR[n+1] - RR[n]$ (ms); la magnitud que se predice
dr_lag0..7	característica: dr_lag0..7: los 8 dRR más recientes (lag0 = el más nuevo)
gbdt	árboles de decisión potenciados por gradiente (nombre de ejecución)
guzik	característica: asimetría de Guzik: suma de dRR positivos / suma de dRR
HRV	variabilidad de la frecuencia cardiaca
int8	entero de 8 bits: pesos y activaciones cuantizados a enteros de 8 bits, como se ejecuta en el microcontrolador; _int8 = la versión int8 de una ejecución
KB	kilobyte (1024 bytes)
L2	regularización L2: penalización sobre la suma de los cuadrados de los pesos del modelo
lr	tasa de aprendizaje (tamaño de paso del optimizador)
MAC	operación de multiplicación-acumulación (una multiplicación más una suma): la unidad de coste de cómputo en el microcontrolador; MACs/latido = cuántas necesita el modelo por latido
MACs	operaciones de multiplicación-acumulación (ver MAC)
MLP	perceptrón multicapa (red neuronal totalmente conectada)
ms	milisegundos
np.corrcoef	función de NumPy para el coeficiente de correlación de Pearson
np.diff	función de NumPy de diferencias sucesivas
Q	factor de calidad de un filtro pasa banda: frecuencia central / ancho de banda
RBJ	fórmulas estándar de filtros biquad (segundo orden) de Robert Bristow-Johnson
RLS	mínimos cuadrados recursivos: filtro adaptativo que actualiza sus coeficientes en cada latido
rls_err	característica: última innovación del RLS: dRR verdadero menos el pronóstico anterior (ms)
rls_pred	característica: pronóstico RLS AR(8) del siguiente dRR (ms), recortado a +-300
RMSE	raíz del error cuadrático medio (ms): la medida principal de precisión, menor es mejor
rmssd	raíz cuadrada media de las diferencias sucesivas de los intervalos RR de la ventana
RR	intervalo RR: tiempo entre dos latidos consecutivos (ondas R del ECG), en ms
rr_dev	característica: RR más reciente menos la media de la ventana
rr_mean	característica: RR medio de la ventana de 30 latidos
rs	rango reescalado: (máx - mín de las desviaciones acumuladas respecto a la media) / desviación estándar
RSA	arritmia sinusal respiratoria: la oscilación de la frecuencia cardiaca provocada por la respiración
run_len	característica: longitud con signo de la racha actual de dRR del mismo signo (+ = desaceleración)
SD1	desviación estándar del diagrama de Poincaré perpendicular a la diagonal (variabilidad a corto plazo)
SD2	desviación estándar del diagrama de Poincaré a lo largo de la diagonal (variabilidad a largo plazo)
tab	nombre de conjunto de características / tipo de modelo: modelo tabular (solo características diseñadas)
TCN	red convolucional temporal (convoluciones 1-D causales y dilatadas)
val	validación: los 16 sujetos de validación, usados para seleccionar el modelo
W	longitud de la ventana: los 30 intervalos RR más recientes
z	puntuación z: (valor - media) / desviación estándar, con estadísticas de los sujetos de entrenamiento