

GRU

Una pequeña red recurrente sobre la secuencia RR más las características diseñadas.

Una GRU de 16 unidades sobre la secuencia de 30 latidos. Precisa en float, pero rechazada porque la cuantización int8 le cuesta 1.6-3.6 ms.

Arquitectura

- GRU(16, desenrollada para obtener un grafo TFLite sin bucles) sobre la secuencia (30, 2); su último estado se concatena con las 9 características y después Dense(32, ReLU) - Dense(1).
- 1825 parámetros, 1696 MACs por latido (streaming con estado), unos 1.8 KB en int8.

Tabla de capas de gru (B = lote)

capa	configuración	forma de salida	parám.
InputLayer		(B, 30, 2)	0
GRU	units=16, activation=tanh, unroll=True	(B, 16)	960
InputLayer		(B, 9)	0
Concatenate		(B, 25)	0
Dense	units=32, activation=relu	(B, 32)	832
Dense	units=1	(B, 1)	33

Entradas e ingeniería de características (gru)

- Entrada de secuencia** (TCN/GRU): los últimos 30 intervalos RR como dos canales, z-RR y z-dRR (dRR del primer paso = 0), normalizados z con media/desviación ajustadas solo sobre los sujetos de entrenamiento (varianza cero -> desviación 1).
- Entrada tabular**: las características diseñadas del latido más reciente (ver 01_feature_engineering.pdf), normalizadas z por característica con estadísticas de entrenamiento.
- Objetivo**: $dRR[n+1] = RR[n+1] - RR[n]$. Los modelos residuales predicen la corrección normalizada z sobre el pronóstico RLS (dRR - rls_pred); la salida se desnormaliza y se suma de nuevo a rls_pred.

Características tabulares (9):

característica	definición
rmssd	raíz cuadrada media de las 29 diferencias sucesivas
rs	rango reescalado: (máx - mín de la suma acumulada de RR - media) / desviación estándar
ccm	medida de correlación compleja: área de los triángulos de Poincaré / (π SD1 SD2 (W-3)), recortada a [0, 1]
guzik	asimetría de Guzik: suma de dRR positivos / suma de dRR
rls_pred	pronóstico RLS AR(8) del siguiente dRR (ms), recortado a +-300
rls_err	última innovación del RLS: dRR verdadero menos el pronóstico anterior (ms)
bp	salida del pasa banda RSA: biquad RBJ sobre el RR crudo, centro 0.30 ciclos/latido, Q 1
bp_prev	salida anterior del pasa banda (junto con bp da la fase)
run_len	longitud con signo de la racha actual de dRR del mismo signo (+ = desaceleración)

Entrenamiento

Keras, AdamW (decaimiento de pesos $1e-4$), pérdida de Huber (delta 1, en unidades z), lote 512, steps_per_execution 64, épocas de 2M ventanas de entrenamiento aleatorias (alrededor del 10% de las 20.8M), EarlyStopping sobre val_loss (restaurando los mejores pesos) y ReduceLROnPlateau (factor 0.5, mínimo $1e-5$), semilla 211. int8: cuantización post-entrenamiento totalmente entera (TFLite, entrada y salida int8), calibración determinista del mejor de K (8 extracciones de 2k/5k ventanas de entrenamiento; se conserva la que tiene la menor diferencia sobre sujetos de entrenamiento reservados).

Variantes entrenadas

ejecución	cambio respecto al padre	conjunto de características (n)	parám.	MACs/latido	entrenamiento	épocas
gru	mismas entradas que las TCNs	seq (9)	1825	1696	desde cero, lr 0.001	49

Resultados

modelo	val lazo abierto	modelo en lazo cerrado	10%	30%	50%	80%	RSA inventada al 80%	test serie completa 80%	fuelle val
gru	33.90	int8	28.04	31.38	35.34	45.07	12%	43.84	ronda 2 (gru)

RMSE en ms. **val lazo abierto**: predicción a un paso sobre la historia verdadera, 16 sujetos de validación. **10-80%**: lazo cerrado (uso en el marcapasos) en validación: se elimina al azar esa proporción de latidos desde el latido 0, cada uno se rellena con el modelo y se realimenta; RMSE sobre los latidos rellenos por el modelo, primeros 5000 latidos por sujeto, media de las semillas de esa ronda (3 semillas desde la ronda 2). Se usa int8 donde existe. **RSA inventada**: proporción de pares sujeto-ejecución cuya serie rellena gana un pico de RSA que la original no tiene. **test serie completa 80%**: diagnóstico sobre los 10 sujetos de test (serie completa, semilla 7, carpeta results/test/); no se usó para ninguna selección.

Correlación entre la serie original y la rellena (sujetos de validación y test)

modelo	corr RR validación	corr RR test	corr dRR validación	corr dRR test	RMSE rellenos, validación (ms)	RMSE rellenos, test (ms)
gru	0.9352	0.9397	0.266	0.263	50.24	43.84

Calculado sobre los 16 sujetos de validación y los 10 de test (carpetas results/validation/ y results/test/), sobre la serie COMPLETA, tras eliminar el 80% de los latidos (semilla 7, desde el latido 0) y rellenos en lazo cerrado con el modelo (relleno Burg-AR en los primeros 30 latidos): **corr RR** = np.corrcoef(original_serie, modified_serie)[0, 1]; **corr dRR** = la misma función sobre los cambios latido a latido, np.corrcoef(np.diff(original), np.diff(filled))[0, 1], que aísla la dinámica a corto plazo. Media sobre sujetos; valores por sujeto en <carpeta>/crosscorr.csv. **RMSE rellenos**: RMSE sobre los latidos rellenos por el modelo en esas mismas ejecuciones. Diagnóstico: la selección usó el protocolo de la ronda 4, no estas ejecuciones.

Veredicto

- Float: empata con micro_tcn en todas las tasas de eliminación con un 19% menos de MACs y supera a mlp en 15/16 sujetos.
- int8: diferencia +2.71% en validación (por encima del límite del 2%) y pérdida de 1.6-3.6 ms en lazo cerrado; además inventa un pico de RSA al 50% en un sujeto: rechazada. Cuantizar el estado recurrente es notoriamente difícil en los MCUs.

Abreviaturas y siglas usadas en este documento

término	significado
AdamW	optimizador Adam con decaimiento de pesos desacoplado (algoritmo de entrenamiento de los modelos neuronales)
AR	autorregresivo: un valor predicho como suma ponderada de valores pasados; AR(p) usa p valores pasados
B	dimensión de lote (número de ventanas procesadas a la vez) en las formas de salida de las capas
bp	característica: salida del pasa banda RSA: biquad RBJ sobre el RR crudo, centro 0.30 ciclos/latido, Q 1
bp_prev	característica: salida anterior del pasa banda (junto con bp da la fase)
Burg-AR	modelo AR cuyos coeficientes se ajustaron con el método de Burg (usado en los primeros 30 latidos)
ccm	medida de correlación compleja: índice de no linealidad del diagrama de Poincaré de intervalos RR consecutivos
dRR	cambio latido a latido del intervalo RR: $dRR[n+1] = RR[n+1] - RR[n]$ (ms); la magnitud que se predice
GRU	unidad recurrente con compuertas (celda de red neuronal recurrente)
gru	unidad recurrente con compuertas (nombre de ejecución)
guzik	característica: asimetría de Guzik: suma de dRR positivos / suma de dRR
HRV	variabilidad de la frecuencia cardiaca
int8	entero de 8 bits: pesos y activaciones cuantizados a enteros de 8 bits, como se ejecuta en el microcontrolador; _int8 = la versión int8 de una ejecución
KB	kilobyte (1024 bytes)
lr	tasa de aprendizaje (tamaño de paso del optimizador)
MAC	operación de multiplicación-acumulación (una multiplicación más una suma): la unidad de coste de cómputo en el microcontrolador; MACs/latido = cuántas necesita el modelo por latido
MACs	operaciones de multiplicación-acumulación (ver MAC)
MCU	microcontrolador
mip	perceptrón multicapa (nombre de ejecución)
ms	milisegundos
np.corrcoef	función de NumPy para el coeficiente de correlación de Pearson
np.diff	función de NumPy de diferencias sucesivas
Q	factor de calidad de un filtro pasa banda: frecuencia central / ancho de banda
RBJ	fórmulas estándar de filtros biquad (segundo orden) de Robert Bristow-Johnson
ReLU	unidad lineal rectificadora, $\max(0, x)$ (función de activación)
RLS	mínimos cuadrados recursivos: filtro adaptativo que actualiza sus coeficientes en cada latido
rls_err	característica: última innovación del RLS: dRR verdadero menos el pronóstico anterior (ms)
rls_pred	característica: pronóstico RLS AR(8) del siguiente dRR (ms), recortado a +-300
RMSE	raíz del error cuadrático medio (ms): la medida principal de precisión, menor es mejor
rmssd	raíz cuadrada media de las diferencias sucesivas de los intervalos RR de la ventana
RR	intervalo RR: tiempo entre dos latidos consecutivos (ondas R del ECG), en ms
rs	rango reescalado: $(\text{máx} - \text{mín de las desviaciones acumuladas respecto a la media}) / \text{desviación estándar}$
RSA	arritmia sinusal respiratoria: la oscilación de la frecuencia cardiaca provocada por la respiración
run_len	característica: longitud con signo de la racha actual de dRR del mismo signo (+ = desaceleración)
SD1	desviación estándar del diagrama de Poincaré perpendicular a la diagonal (variabilidad a corto plazo)
SD2	desviación estándar del diagrama de Poincaré a lo largo de la diagonal (variabilidad a largo plazo)
seq	nombre de conjunto de características / tipo de modelo: modelo de secuencia (toma la ventana RR cruda más características tabulares)
TCN	red convolucional temporal (convoluciones 1-D causales y dilatadas)
tcn	red convolucional temporal (parte del nombre de ejecución)
TFLite	TensorFlow Lite: entorno de ejecución y formato de archivo para modelos en dispositivos embebidos
val	validación: los 16 sujetos de validación, usados para seleccionar el modelo
W	longitud de la ventana: los 30 intervalos RR más recientes
z	puntuación z: $(\text{valor} - \text{media}) / \text{desviación estándar}$, con estadísticas de los sujetos de entrenamiento