

tcn_lite (TCN causal completa) - familia seleccionada

TCN causal de convolución completa, 24 filtros: el modelo seleccionado tcn_lite_ft.

Seleccionado: tcn_lite_ft_int8. El mismo grafo que tcn_lite, con unas pocas épocas más de ajuste fino. No pierde frente a ningún otro candidato en el lazo cerrado int8 en validación. Test final (10 sujetos): lazo abierto 28.59 ms frente a rls_ar 31.15; lazo cerrado 28.25 / 30.20 / 33.07 / 41.55 ms con el 10/30/50/80% eliminado; ningún pico de RSA inventado ni desplazado.

Arquitectura

- Tronco Conv1D puntual (24 filtros) + BatchNorm + ReLU, después 4 bloques residuales de Conv1D causal completa (núcleo 3, dilataciones 1, 2, 4, 7) con relleno explícito a la izquierda, BatchNorm (fusionada al exportar) y ReLU.
- Campo receptivo de 29 latidos (modelo de ventana = modelo en streaming). El paso temporal más reciente se concatena con las 9 características y después Dense(32, ReLU) - Dense(1).
- 8561 parámetros, 8048 MACs por latido en modo streaming (por debajo del límite de 10k), 8.4 KB en int8; int8 cuesta +0.5% en test.

Tabla de capas de tcn_lite (B = lote)

capa	configuración	forma de salida	parám.
InputLayer		(B, 30, 2)	0
Conv1D	filters=24	(B, 30, 24)	48
BatchNormalization		(B, 30, 24)	96
ReLU		(B, 30, 24)	0
ZeroPadding1D	padding=(2, 0), left=2	(B, 32, 24)	0
Conv1D	filters=24, kernel_size=3	(B, 30, 24)	1728
BatchNormalization		(B, 30, 24)	96
ReLU		(B, 30, 24)	0
Add		(B, 30, 24)	0
ZeroPadding1D	padding=(4, 0), left=4	(B, 34, 24)	0
Conv1D	filters=24, kernel_size=3, dilation_rate=2	(B, 30, 24)	1728
BatchNormalization		(B, 30, 24)	96
ReLU		(B, 30, 24)	0
Add		(B, 30, 24)	0
ZeroPadding1D	padding=(8, 0), left=8	(B, 38, 24)	0
Conv1D	filters=24, kernel_size=3, dilation_rate=4	(B, 30, 24)	1728
BatchNormalization		(B, 30, 24)	96
ReLU		(B, 30, 24)	0
Add		(B, 30, 24)	0
ZeroPadding1D	padding=(14, 0), left=14	(B, 44, 24)	0
Conv1D	filters=24, kernel_size=3, dilation_rate=7	(B, 30, 24)	1728
BatchNormalization		(B, 30, 24)	96
ReLU		(B, 30, 24)	0
Add		(B, 30, 24)	0
Cropping1D		(B, 1, 24)	0
Flatten		(B, 24)	0
InputLayer		(B, 9)	0
Concatenate		(B, 33)	0
Dense	units=32, activation=relu	(B, 32)	1088
Dense	units=1	(B, 1)	33

Entradas e ingeniería de características (tcn_lite)

- **Entrada de secuencia** (TCN/GRU): los últimos 30 intervalos RR como dos canales, z-RR y z-dRR (dRR del primer paso = 0), normalizados z con media/desviación ajustadas solo sobre los sujetos de entrenamiento (varianza cero -> desviación 1).

- **Entrada tabular:** las características diseñadas del latido más reciente (ver 01_feature_engineering.pdf), normalizadas z por característica con estadísticas de entrenamiento.
- **Objetivo:** $dRR[n+1] = RR[n+1] - RR[n]$. Los modelos residuales predicen la corrección normalizada z sobre el pronóstico RLS ($dRR - rls_pred$); la salida se desnormaliza y se suma de nuevo a rls_pred .

Características tabulares (9):

característica	definición
rmssd	raíz cuadrada media de las 29 diferencias sucesivas
rs	rango reescalado: (máx - mín de la suma acumulada de RR - media) / desviación estándar
ccm	medida de correlación compleja: área de los triángulos de Poincaré / ($\pi SD1 SD2 (W-3)$), recortada a [0, 1]
guzik	asimetría de Guzik: suma de dRR positivos / suma de dRR
rls_pred	pronóstico RLS AR(8) del siguiente dRR (ms), recortado a +-300
rls_err	última innovación del RLS: dRR verdadero menos el pronóstico anterior (ms)
bp	salida del pasa banda RSA: biquad RBJ sobre el RR crudo, centro 0.30 ciclos/latido, Q 1
bp_prev	salida anterior del pasa banda (junto con bp da la fase)
run_len	longitud con signo de la racha actual de dRR del mismo signo (+ = desaceleración)

Entrenamiento

Keras, AdamW (decaimiento de pesos $1e-4$), pérdida de Huber (delta 1, en unidades z), lote 512, steps_per_execution 64, épocas de 2M ventanas de entrenamiento aleatorias (alrededor del 10% de las 20.8M), EarlyStopping sobre val_loss (restaurando los mejores pesos) y ReduceLROnPlateau (factor 0.5, mínimo $1e-5$), semilla 211. int8: cuantización post-entrenamiento totalmente entera (TFLite, entrada y salida int8), calibración determinista del mejor de K (8 extracciones de 2k/5k ventanas de entrenamiento; se conserva la que tiene la menor diferencia sobre sujetos de entrenamiento reservados).

Variantes entrenadas

ejecución	cambio respecto al padre	conjunto de características (n)	parám.	MACs/latido	entrenamiento	épocas
tcn_lite	base de la ronda 1 (unas 48 pasadas completas)	seq (9)	8561	8048	desde cero, lr 0.001	48
tcn_lite_ft	mismo modelo, ajuste fino (lr $3e-4$); control de la ejecución DAD. SELECCIONADO	seq (9)	8561	8048	ajuste fino de tcn_lite, lr 0.0003	7
tcn_lite_dad	ajuste fino con datos rellenados en lazo cerrado (DAD)	seq (9)	8561	8048	ajuste fino de tcn_lite, lr 0.0003, proporción de datos de lazo cerrado 0.5	18
tcn_lite_rsa	+ características de RSA con bloqueo (seq_rsa), desde cero	seq_rsa (13)	8689	8176	desde cero, lr 0.001	37
tcn_lite_rsa_ws	+ características de RSA con bloqueo, arranque en caliente (entradas nuevas a cero)	seq_rsa (13)	8689	8176	ajuste fino de tcn_lite, lr 0.0003	7

Resultados

modelo	val lazo abierto	modelo en lazo cerrado	10%	30%	50%	80%	RSA inventada al 80%	test serie completa 80%	fuentes val
tcn_lite	32.64	int8	25.91	29.20	33.23	41.82	4%	43.73	ronda 4
tcn_lite_ft	32.62	int8	25.87	29.12	33.13	41.66	0%	43.74	ronda 4
tcn_lite_dad	33.09	int8	26.32	29.34	33.22	41.38	4%	42.91	ronda 4
tcn_lite_rsa	33.06	int8	26.18	29.40	33.23	42.30	0%	45.97	ronda 4
tcn_lite_rsa_ws	32.62	int8	25.87	29.10	33.12	41.86	0%	43.97	ronda 4

RMSE en ms. **val lazo abierto:** predicción a un paso sobre la historia verdadera, 16 sujetos de validación. **10-80%:** lazo cerrado (uso en el marcapasos) en validación: se elimina al azar esa proporción de latidos desde el latido 0, cada uno se rellena con el modelo y se realimenta; RMSE sobre los latidos rellenados por el modelo, primeros 5000 latidos por sujeto, media de las semillas de esa ronda (3 semillas desde la ronda 2). Se usa int8 donde existe. **RSA inventada:** proporción de pares sujeto-ejecución cuya serie rellena gana un pico de RSA que la original no tiene. **test serie completa 80%:** diagnóstico sobre los 10 sujetos de test (serie completa, semilla 7, carpeta results/test/); no se usó para ninguna selección.

Correlación entre la serie original y la rellenada (sujetos de validación y test)

modelo	corr RR validación	corr RR test	corr dRR validación	corr dRR test	RMSE rellenados, validación (ms)	RMSE rellenados, test (ms)
tcn_lite	0.9352	0.9394	0.270	0.264	50.27	43.73
tcn_lite_ft	0.9356	0.9395	0.272	0.266	50.15	43.62
tcn_lite_dad	0.9383	0.9425	0.282	0.278	49.26	42.91
tcn_lite_rsa	0.9311	0.9337	0.261	0.246	51.87	45.97
tcn_lite_rsa_ws	0.9350	0.9385	0.270	0.260	50.40	43.97
tcn_lite_ft_int8	0.9354	0.9393	0.269	0.263	50.18	43.74

Calculado sobre los 16 sujetos de validación y los 10 de test (carpetas results/validation/ y results/test/), sobre la serie COMPLETA, tras eliminar el 80% de los latidos (semilla 7, desde el latido 0) y rellenarlos en lazo cerrado con el modelo (relleno Burg-AR en los primeros 30 latidos): **corr RR** = np.corrcoef(original_serie, modified_serie)[0, 1]; **corr dRR** = la misma función sobre los cambios latido a latido, np.corrcoef(np.diff(original), np.diff(filled))[0, 1], que aísla la dinámica a corto plazo. Media sobre sujetos; valores por sujeto en <carpeta>/crosscorr.csv. **RMSE rellenados**: RMSE sobre los latidos rellenados por el modelo en esas mismas ejecuciones. Diagnóstico: la selección usó el protocolo de la ronda 4, no estas ejecuciones.

Por sujeto de validación (16): modelo desplegado frente a TCN_MHA y rls_ar

sujeto	RR tcn_lite_ft_int8	RR tcn_mha_current	RR rls_ar	dRR tcn_lite_ft_int8	dRR tcn_mha_current	dRR rls_ar
000	0.9377	0.9021	0.9286	0.305	0.161	0.248
006	0.9225	0.8703	0.9068	0.220	0.096	0.165
008	0.9178	0.8873	0.9056	0.245	0.131	0.204
16273	0.8988	0.8366	0.8888	0.288	0.129	0.262
16483	0.9453	0.9423	0.9336	0.258	0.233	0.186
18177	0.9392	0.9378	0.9278	0.255	0.242	0.203
19088	0.9097	0.9007	0.9072	0.242	0.191	0.239
nsr010RRcl	0.9532	0.9421	0.9364	0.300	0.217	0.182
nsr016RRcl	0.9758	0.9711	0.9678	0.256	0.169	0.177
nsr018RRcl	0.9309	0.9173	0.8982	0.412	0.300	0.250
nsr022RRcl	0.9171	0.8718	0.9063	0.275	0.155	0.236
nsr038RRcl	0.9455	0.9445	0.9342	0.158	0.151	0.108
nsr041RRcl	0.9467	0.9446	0.8636	0.274	0.259	0.140
nsr045RRcl	0.9455	0.9344	0.9340	0.365	0.266	0.264
nsr048RRcl	0.9288	0.9019	0.9174	0.221	0.125	0.174
nsr054RRcl	0.9521	0.9477	0.9419	0.233	0.192	0.192

Por sujeto de test (10): modelo desplegado frente a TCN_MHA y rls_ar

sujeto	RR tcn_lite_ft_int8	RR tcn_mha_current	RR rls_ar	dRR tcn_lite_ft_int8	dRR tcn_mha_current	dRR rls_ar
003	0.9053	0.9002	0.8973	0.289	0.263	0.263
007	0.9464	0.9399	0.9410	0.229	0.191	0.200
16420	0.9360	0.9172	0.9087	0.252	0.138	0.226
16539	0.8188	0.7619	0.8066	0.338	0.183	0.331
16786	0.9341	0.9009	0.9276	0.279	0.115	0.257
nsr003RRcl	0.9453	0.9368	0.9298	0.297	0.220	0.261
nsr013RRcl	0.9816	0.9816	0.9795	0.247	0.246	0.201
nsr026RRcl	0.9891	0.9825	0.9774	0.236	0.128	0.114
nsr033RRcl	0.9567	0.9190	0.9345	0.223	0.099	0.154
nsr034RRcl	0.9796	0.9778	0.9734	0.238	0.209	0.178

Veredicto

- tcn_lite_ft_int8 supera a micro_tcn con el 10% y el 30% eliminado ($p \leq 0.003$, el float coincide) y a tcn_lite en el agrupado; solo empata con tcn_lite_dad (mismo tamaño; la ganancia de 0.28 ms de DAD al 80% no es significativa).

- Las características de RSA con bloqueo no aportan nada al 10-50% y cuestan 0.2 ms al 80%; tcn_lite_rsa desde cero queda confundido por un presupuesto de entrenamiento 13 veces menor.
- Con el 80% eliminado todos los modelos amortiguan la potencia de la RSA (aprox. $\times 0.5$): un límite de información, no un defecto; el modelo seleccionado no inventó ningún pico de RSA en validación ni en test; sus marcas de pico desplazado en validación (solo en los 2 sujetos con RSA) no fueron más frecuentes que las de rls_ar, y en test no hubo ninguna.

Abreviaturas y siglas usadas en este documento

término	significado
AdamW	optimizador Adam con decaimiento de pesos desacoplado (algoritmo de entrenamiento de los modelos neuronales)
AR	autorregresivo: un valor predicho como suma ponderada de valores pasados; AR(p) usa p valores pasados
ar	nombre de conjunto de características: entradas autorregresivas (rr_dev y los 8 dRR más recientes) del modelo lineal
B	dimensión de lote (número de ventanas procesadas a la vez) en las formas de salida de las capas
bp	característica: salida del pasa banda RSA: biquad RBJ sobre el RR crudo, centro 0.30 ciclos/latido, Q 1
bp_prev	característica: salida anterior del pasa banda (junto con bp da la fase)
Burg-AR	modelo AR cuyos coeficientes se ajustaron con el método de Burg (usado en los primeros 30 latidos)
ccm	medida de correlación compleja: índice de no linealidad del diagrama de Poincaré de intervalos RR consecutivos
Conv1D	capa de convolución unidimensional
DAD	data as demonstrator: entrenamiento con entradas que contienen los rellenos de lazo cerrado del propio modelo, con el objetivo verdadero (remedio contra el sesgo de exposición)
_dad	sufijo de nombre de ejecución: ajuste fino con datos DAD (rellenados en lazo cerrado)
dRR	cambio latido a latido del intervalo RR: $dRR[n+1] = RR[n+1] - RR[n]$ (ms); la magnitud que se predice
_ft	sufijo de nombre de ejecución: ajuste fino (entrenamiento continuado desde los pesos del modelo padre)
GRU	unidad recurrente con compuertas (celda de red neuronal recurrente)
guzik	característica: asimetría de Guzik: suma de dRR positivos / suma de dRR
HRV	variabilidad de la frecuencia cardiaca
int8	entero de 8 bits: pesos y activaciones cuantizados a enteros de 8 bits, como se ejecuta en el microcontrolador; _int8 = la versión int8 de una ejecución
KB	kilobyte (1024 bytes)
lr	tasa de aprendizaje (tamaño de paso del optimizador)
MAC	operación de multiplicación-acumulación (una multiplicación más una suma): la unidad de coste de cómputo en el microcontrolador; MACs/latido = cuántas necesita el modelo por latido
MACs	operaciones de multiplicación-acumulación (ver MAC)
MHA	atención multicabeza (capa de tipo transformer, no soportada por la cadena de herramientas del MCU)
ms	milisegundos
np.corrcoef	función de NumPy para el coeficiente de correlación de Pearson
np.diff	función de NumPy de diferencias sucesivas
nsrNNRRcI	código de sujeto de una serie RR de los registros de ritmo sinusal normal (NSR) (archivo data/series/<código>.txt); los códigos puramente numéricos como 16273 o 006 son otros sujetos
p	valor p de la prueba de Wilcoxon pareada por sujeto: probabilidad de una diferencia al menos tan grande si los dos modelos fueran igual de precisos ($p < 0.05$ = significativo); en AR(p), el número de valores pasados
Q	factor de calidad de un filtro pasa banda: frecuencia central / ancho de banda
RBJ	fórmulas estándar de filtros biquad (segundo orden) de Robert Bristow-Johnson
ReLU	unidad lineal rectificada, $\max(0, x)$ (función de activación)
RLS	mínimos cuadrados recursivos: filtro adaptativo que actualiza sus coeficientes en cada latido
rls_ar	referencia: pronóstico AR(8) adaptativo por paciente mediante RLS
rls_err	característica: última innovación del RLS: dRR verdadero menos el pronóstico anterior (ms)
rls_pred	característica: pronóstico RLS AR(8) del siguiente dRR (ms), recortado a +300
RMSE	raíz del error cuadrático medio (ms): la medida principal de precisión, menor es mejor
rmssd	raíz cuadrada media de las diferencias sucesivas de los intervalos RR de la ventana
RR	intervalo RR: tiempo entre dos latidos consecutivos (ondas R del ECG), en ms
rs	rango reescalado: (máx - mín de las desviaciones acumuladas respecto a la media) / desviación estándar
RSA	arritmia sinusal respiratoria: la oscilación de la frecuencia cardiaca provocada por la respiración
_rsa	sufijo de nombre de ejecución: usa las características del seguidor de RSA
run_len	característica: longitud con signo de la racha actual de dRR del mismo signo (+ = desaceleración)
SD1	desviación estándar del diagrama de Poincaré perpendicular a la diagonal (variabilidad a corto plazo)
SD2	desviación estándar del diagrama de Poincaré a lo largo de la diagonal (variabilidad a largo plazo)
seq	nombre de conjunto de características / tipo de modelo: modelo de secuencia (toma la ventana RR cruda más características tabulares)
TCN	red convolucional temporal (convoluciones 1-D causales y dilatadas)
tcn	red convolucional temporal (parte del nombre de ejecución)
TFLite	TensorFlow Lite: entorno de ejecución y formato de archivo para modelos en dispositivos embebidos

término	significado
val	validación: los 16 sujetos de validación, usados para seleccionar el modelo
W	longitud de la ventana: los 30 intervalos RR más recientes
_ws	sufijo de nombre de ejecución: arranque en caliente (inicializado con los pesos del padre, entradas nuevas a cero)
z	puntuación z: (valor - media) / desviación estándar, con estadísticas de los sujetos de entrenamiento