

TCN_MHA (modelo de producción heredado)

El modelo de producción anterior: TCN causal con atención multicabeza, juzgado como un candidato más.

El modelo de producción actual, evaluado como un candidato más (no como referencia). No se puede desplegar en el microcontrolador y tcn_lite lo supera en casi todos los sujetos.

Arquitectura

- Tronco de convoluciones causales multiescala (núcleos 3, 5 y 9, 16 filtros cada uno, GELU), concatenado a 48 canales.
- Cuatro bloques residuales de dos Conv1D causales (48, núcleo 3) con LayerNormalization, GELU y SpatialDropout(0.1), dilataciones 1, 2, 4 y 8.
- MultiHeadAttention sobre los 30 pasos temporales (4 cabezas, dimensión de clave 12) con conexión residual y LayerNorm, y después GlobalAveragePooling1D.
- Rama de características estáticas: Dense(32, GELU) + LayerNorm, usada para modular la secuencia agregada (compuertas de multiplicación y suma) antes de una cabeza Dense(64, GELU) + LayerNorm, Dense(32, GELU), Dense(1).
- 77 345 parámetros (unos 75.5 KB en int8) y unos 2 040 576 MACs por predicción; no se puede ejecutar en streaming.
- Entrenado en el pipeline heredado con RSAPhaseAwareLoss: Huber + una penalización de signo + una penalización de ajuste de varianza. El término de varianza premia la oscilación, una causa plausible de sus picos de RSA inventados.

Tabla de capas (B = lote)

capa	configuración	forma de salida	parám.
InputLayer		(B, 30, 1)	0
Conv1D	filters=16, kernel_size=3, activation=gelu, padding=causal	(B, 30, 16)	64
Conv1D	filters=16, kernel_size=5, activation=gelu, padding=causal	(B, 30, 16)	96
Conv1D	filters=16, kernel_size=9, activation=gelu, padding=causal	(B, 30, 16)	160
Concatenate		(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Add		(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, dilation_rate=2, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, dilation_rate=2, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Add		(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, dilation_rate=4, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, dilation_rate=4, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Add		(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, dilation_rate=8, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Conv1D	filters=48, kernel_size=3, dilation_rate=8, padding=causal	(B, 30, 48)	6960
LayerNormalization		(B, 30, 48)	96
Activation	activation=gelu	(B, 30, 48)	0
SpatialDropout1D	rate=0.1	(B, 30, 48)	0
Add		(B, 30, 48)	0
MultiHeadAttention	num_heads=4, key_dim=12	(B, 30, 48)	9408
InputLayer		(B, 12)	0
Add		(B, 30, 48)	0
Dense	units=32, activation=gelu	(B, 32)	416
LayerNormalization		(B, 30, 48)	96
LayerNormalization		(B, 32)	64
GlobalAveragePooling1D		(B, 48)	0
Dense	units=48	(B, 48)	1584
Multiply		(B, 48)	0
Dense	units=48	(B, 48)	1584
Add		(B, 48)	0
Concatenate		(B, 80)	0
Dense	units=64, activation=gelu	(B, 64)	5184

capa	configuración	forma de salida	parám.
LayerNormalization		(B, 64)	128
Dense	units=32, activation=gelu	(B, 32)	2080
Dense	units=1	(B, 1)	33

Entradas y preprocesado

- Secuencia: los últimos 30 RR, un canal, normalizados z con estadísticas globales de data/hrv_dataset.h5.
- 12 características estáticas recalculadas en cada ventana con legacy/utis2.py: rmssd, rs, ccm, ccm_n5, guzik, nn20, porta, ar_1, ar_2, ar_3, ar_4, ar_5, normalizadas z con las estadísticas de data/hrv_dataset.h5.
- Objetivo: dRR[n+1], desnormalizado con la media/desviación del objetivo guardadas (sin residual sobre el RLS).

Resultados

conjunto	lazo abierto	cerrado 10%	cerrado 30%	cerrado 50%	cerrado 80%	notas
validación (ronda 2)	33.72	26.07	29.43	33.65	43.88	RSA inventada al 80%: 12% de los pares sujeto-ejecución
test (final)	29.11	28.58	30.63	33.90	42.53	solo float
test serie completa, 80%	-	-	-	-	50.11	potencia de RSA x1.18, inventados 0.2, desplazados 0.4 por sujeto

Correlación entre la serie original y la rellenada (sujetos de validación y test)

modelo	corr RR validación	corr RR test	corr dRR validación	corr dRR test	RMSE rellenados, validación (ms)	RMSE rellenados, test (ms)
tcn_mha_current	0.9158	0.9218	0.189	0.179	57.45	50.11
tcn_lite_ft_int8	0.9354	0.9393	0.269	0.263	50.18	43.74
rls_ar	0.9186	0.9276	0.202	0.219	56.34	49.15

Calculado sobre los 16 sujetos de validación y los 10 de test (carpetas results/validation/ y results/test/), sobre la serie COMPLETA, tras eliminar el 80% de los latidos (semilla 7, desde el latido 0) y rellenarlos en lazo cerrado con el modelo (relleno Burg-AR en los primeros 30 latidos): **corr RR** = np.corrcoef(original_serie, modified_serie)[0, 1]; **corr dRR** = la misma función sobre los cambios latido a latido, np.corrcoef(np.diff(original), np.diff(filled))[0, 1], que aísla la dinámica a corto plazo. Media sobre sujetos; valores por sujeto en <carpeta>/crosscorr.csv. **RMSE rellenados**: RMSE sobre los latidos rellenados por el modelo en esas mismas ejecuciones. Diagnóstico: la selección usó el protocolo de la ronda 4, no estas ejecuciones.

Veredicto

- No válido para el MCU (atención, LayerNorm, GELU, agregación global, 75.5 KB, unos 2M MACs).
- tcn_lite lo supera en 16/16 sujetos de validación en lazo abierto y en 14/16 en lazo cerrado, y tcn_lite_ft_int8 en 10/10 sujetos de test en lazo abierto.
- Inventa o desplaza picos de RSA en el lazo cerrado (visible en los espectros de results/test/<sujeto>/tcn_mha_current/), el fallo que dio origen a este trabajo. Las TCNs lo hicieron como mucho en el 4% de los pares sujeto-ejecución de validación con el 80% eliminado y nunca en los sujetos de test.

Abreviaturas y siglas usadas en este documento

término	significado
AR	autorregresivo: un valor predicho como suma ponderada de valores pasados; AR(p) usa p valores pasados
ar	nombre de conjunto de características: entradas autorregresivas (rr_dev y los 8 dRR más recientes) del modelo lineal
B	dimensión de lote (número de ventanas procesadas a la vez) en las formas de salida de las capas
Burg-AR	modelo AR cuyos coeficientes se ajustaron con el método de Burg (usado en los primeros 30 latidos)
ccm	medida de correlación compleja: índice de no linealidad del diagrama de Poincaré de intervalos RR consecutivos
Conv1D	capa de convolución unidimensional
dRR	cambio latido a latido del intervalo RR: $dRR[n+1] = RR[n+1] - RR[n]$ (ms); la magnitud que se predice
_ft	sufijo de nombre de ejecución: ajuste fino (entrenamiento continuado desde los pesos del modelo padre)
GELU	unidad lineal de error gaussiano (función de activación)
guzik	característica: asimetría de Guzik: suma de dRR positivos / suma de dRR
HRV	variabilidad de la frecuencia cardiaca
int8	entero de 8 bits: pesos y activaciones cuantizados a enteros de 8 bits, como se ejecuta en el microcontrolador; _int8 = la versión int8 de una ejecución
KB	kilobyte (1024 bytes)
MAC	operación de multiplicación-acumulación (una multiplicación más una suma): la unidad de coste de cómputo en el microcontrolador; MACs/latido = cuántas necesita el modelo por latido
MACs	operaciones de multiplicación-acumulación (ver MAC)
MCU	microcontrolador
MHA	atención multicabeza (capa de tipo transformer, no soportada por la cadena de herramientas del MCU)
ms	milisegundos
nn20	número de diferencias sucesivas de RR mayores de 20 ms en la ventana
np.corrcoef	función de NumPy para el coeficiente de correlación de Pearson
np.diff	función de NumPy de diferencias sucesivas
porta	característica: asimetría de Porta: número de dRR negativos / número de dRR no nulos
RLS	mínimos cuadrados recursivos: filtro adaptativo que actualiza sus coeficientes en cada latido
rls_ar	referencia: pronóstico AR(8) adaptativo por paciente mediante RLS
RMSE	raíz del error cuadrático medio (ms): la medida principal de precisión, menor es mejor
rmssd	raíz cuadrada media de las diferencias sucesivas de los intervalos RR de la ventana
RR	intervalo RR: tiempo entre dos latidos consecutivos (ondas R del ECG), en ms
rs	rango reescalado: (máx - mín de las desviaciones acumuladas respecto a la media) / desviación estándar
RSA	arritmia sinusal respiratoria: la oscilación de la frecuencia cardiaca provocada por la respiración
TCN	red convolucional temporal (convoluciones 1-D causales y dilatadas)
tcn	red convolucional temporal (parte del nombre de ejecución)
z	puntuación z: (valor - media) / desviación estándar, con estadísticas de los sujetos de entrenamiento