

# Entrenamiento: gbdt (árboles potenciados por gradiente)

HistGradientBoosting ajustado sobre las características tabulares, con parada temprana en validación.

Árboles potenciados por gradiente, ajustados en CPU en unos 2 minutos. Son solo una referencia de precisión y de importancia de características: 500 árboles son demasiado grandes para el microcontrolador.

## Cómo se entrena

- HistGradientBoostingRegressor de scikit-learn: error cuadrático, tasa de aprendizaje 0.05, como máximo 500 árboles de profundidad 6 y 31 hojas, al menos 100 ventanas por hoja, L2 1.0, random\_state 211.
- Datos: las 20 755 925 ventanas de entrenamiento (la biblioteca agrupa las características en histogramas), objetivo residual dRR - rls\_pred en unidades z. Parada temprana sobre las ventanas de validación de sujetos disjuntos (pasadas como X\_val), tras 20 árboles sin mejora; nunca se activó: ambas ejecuciones usaron los 500 árboles.
- Tras el ajuste: importancia por permutación sobre hasta 50 000 ventanas de validación (5 repeticiones) y la correlación de Spearman de todas las características del motor sobre ventanas de entrenamiento, guardadas como feature\_importance.csv y feature\_correlation.csv en la carpeta de la ejecución.
- Comandos: python src/train.py --models gbdt; python src/train.py --models gbdt --features all --tag gbdt\_all (ejecutados en CPU).

## Ejecuciones

| ejecución | características | árboles | ajuste  | RMSE val (ms) | rls_ar (ms) |
|-----------|-----------------|---------|---------|---------------|-------------|
| gbdt      | 19              | 500     | 124.5 s | 34.19         | 37.14       |
| gbdt_all  | 29              | 500     | 134.8 s | 34.15         | 37.14       |

## Qué mostró el entrenamiento

- Ambas ejecuciones llegaron al tope de 500 árboles: más árboles quizá ayudarían, pero el modelo ya ocupa unos 238 KB a 8 B por nodo (presupuesto 32 KB), así que no se continuó.
- gbdt\_all (todas las características del motor) es solo 0.04 ms mejor: su importancia por permutación sitúa rls\_pred primera con mucha diferencia (0.118 z), después rr\_dev, drr\_lag0, guzik y bp; los 8 pesos del RLS no aportan nada.

## Abreviaturas y siglas usadas en este documento

| término     | significado                                                                                                          |
|-------------|----------------------------------------------------------------------------------------------------------------------|
| ar          | nombre de conjunto de características: entradas autorregresivas (rr_dev y los 8 dRR más recientes) del modelo lineal |
| B           | dimensión de lote (número de ventanas procesadas a la vez) en las formas de salida de las capas                      |
| bp          | característica: salida del pasa banda RSA: biquad RBJ sobre el RR crudo, centro 0.30 ciclos/latido, Q 1              |
| CPU         | unidad central de procesamiento                                                                                      |
| dRR         | cambio latido a latido del intervalo RR: $dRR[n+1] = RR[n+1] - RR[n]$ (ms); la magnitud que se predice               |
| drr_lag0..7 | característica: drr_lag0..7: los 8 dRR más recientes (lag0 = el más nuevo)                                           |
| gbdt        | árboles de decisión potenciados por gradiente (nombre de ejecución)                                                  |
| guzik       | característica: asimetría de Guzik: suma de dRR positivos / suma de  dRR                                             |
| HRV         | variabilidad de la frecuencia cardiaca                                                                               |
| KB          | kilobyte (1024 bytes)                                                                                                |
| L2          | regularización L2: penalización sobre la suma de los cuadrados de los pesos del modelo                               |
| ms          | milisegundos                                                                                                         |
| RLS         | mínimos cuadrados recursivos: filtro adaptativo que actualiza sus coeficientes en cada latido                        |
| rls_ar      | referencia: pronóstico AR(8) adaptativo por paciente mediante RLS                                                    |
| rls_pred    | característica: pronóstico RLS AR(8) del siguiente dRR (ms), recortado a +300                                        |
| RMSE        | raíz del error cuadrático medio (ms): la medida principal de precisión, menor es mejor                               |
| rr_dev      | característica: RR más reciente menos la media de la ventana                                                         |
| val         | validación: los 16 sujetos de validación, usados para seleccionar el modelo                                          |
| z           | puntuación z: (valor - media) / desviación estándar, con estadísticas de los sujetos de entrenamiento                |